Bericht Optimierung

Lukas Panni

08.11.2022

1. Schnittpunkttest optimieren

Sourcecode optimierte Version:

Listing 1: intersects optimiert

```
bool intersects(Vector<T, 3> origin, Vector<T, 3> direction,
 2
   FLOAT &t, FLOAT &u, FLOAT &v, FLOAT minimum_t)
 3
 4
   Vector<T, 3> normal = cross_product(p2 - p1, p3 - p1);
   T normalRayProduct = normal.scalar_product(direction);
 6
 8
    if (fabs(normalRayProduct) < EPSILON)</pre>
 9
10
     return false;
11
12
   T d = normal.scalar_product(p1);
13
   |t = (d - normal.scalar_product(origin)) / normalRayProduct;
15
   if (t < 0.0 || t > minimum_t)
16
17
18
     return false;
19
20
21
   Vector<T, 3> intersection = origin + t * direction;
23
    Vector<T, 3> vector = cross_product(p2 - p1, intersection - p1);
24
   if (normal.scalar_product(vector) < 0.0)</pre>
25
26
     return false;
27
29
   vector = cross_product(p3 - p2, intersection - p2);
   if (normal.scalar_product(vector) < 0.0)</pre>
31
   | {
32
    return false;
33
   }
34
   Vector<T, 3> vectorV = cross_product(p1 - p3, intersection - p3);
36
   if (normal.scalar_product(vectorV) < 0.0)</pre>
37
38
    return false;
39
40
41 | T squareArea = normal.square_of_length();
```

```
42 | v = sqrt(vectorV.square_of_length() / squareArea);
44 | u = sqrt(vector.square_of_length() / squareArea);
45 | return true;
46 | }
```

Die Änderungen beziehen sich insbesondere auf die Berechnung von u und v. Diese wurden ans Ende der Funktion verschoben, da die Werte nur benötigt werden, wenn ein Schnittpunkt existiert. Zur Reduktion der Wurzelfunktion wurde die Berechnung von u und v angepasst: Anstatt die Länge durch die Fläche zu teilen, wird das Quadrat der Länge durch das Quadrat der Fläche geteilt und im Anschluss die Wurzel gezogen. Da bei der Berechnung der Länge und der Fläche jeweils die Wurzel aus dem jeweiligen Quadrat gezogen wird, kann so die Anzahl der sqrt Operationen von 3 ($2L\ddot{a}nge + Fl\ddot{a}che$) auf 2 (2(QuadratischeLänge/QuadratischeFläche)) reduziert werden. Außerdem wird durch Prüfung, ob bereits ein näherer Schnittpunkt gefunden wird, ein früherer Abbruch der Funktion ermöglicht.

Assembler

Der Assembler-Code wurde ohne Compiler-Optimierung erzeugt, um die Lesbarkeit zu verbessern. Für die Ermöglichung des früheren Abbruchs (Überprüfung auf t > minimum_t) werden mehr Assembler-Befehle erzeugt. Der zweite Vergleich erfordert neben einer Vergleichsoperation (VCOMISS) auch einen zusätzlichen Sprungbefehl (ja und jbe im Vergleich zu nur jbe).

unoptimiert:

Listing 2: Assembler minimum_t unoptimiert

```
1
   if (t < 0.0)
 2
   239: 48 8b 85 30 ff ff ff mov -0xd0(%rbp), %rax
 3
   240: c5 fa 10 08 vmovss (%rax), %xmm1
   244: c5 f8 57 c0 vxorps %xmm0, %xmm0, %xmm0
 5
   248: c5 f8 2f c1 vcomiss %xmm1, %xmm0
   24c: 76 0a jbe 258 <\

→ _ZN8TriangleIfE10intersectsE6VectorIfLm3EES2_RfS3_S3_f+0

       7
   {
 8
   return false:
   24e: b8 00 00 00 00 mov $0x0, %eax
   253: e9 1b 04 00 00 jmpq 673 <\
10

→ _ZN8TriangleIfE10intersectsE6VectorIfLm3EES2_RfS3_S3_f+0

→ x673>

   }
11
```

optimiert:

Listing 3: Assembler minimum_t optimiert

```
if (t < 0.0 || t > minimum_t)
 2
  229: 48 8b 85 20 ff ff ff mov -0xe0(%rbp), %rax
  230: c5 fa 10 08 vmovss (%rax), %xmm1
  234: c5 f8 57 c0 vxorps %xmm0, %xmm0, %xmm0
   238: c5 f8 2f c1 vcomiss %xmm1, %xmm0
   23c: 77 15 ja 253 <\

→ _ZN8TriangleIfE10intersectsE6VectorIfLm3EES2_RfS3_S3_f+0

→ x253>

 7
   23e: 48 8b 85 20 ff ff ff mov -0xe0(%rbp), %rax
   245: c5 fa 10 00 vmovss (%rax), %xmm0
   249: c5 f8 2f 85 0c ff ff vcomiss -0xf4(%rbp),%xmm0
10 250: ff
   251: 76 0a jbe 25d <\

→ _ZN8TriangleIfE10intersectsE6VectorIfLm3EES2_RfS3_S3_f+0

       {
12
13
   return false:
   253: b8 00 00 00 00 mov $0x0, %eax
  258: e9 7a 04 00 00 jmpq 6d7 <\

→ _ZN8TriangleIfE10intersectsE6VectorIfLm3EES2_RfS3_S3_f+0

→ x6d7>

16
```

Die Optimierung der Berechnung von u und v führt zur Reduktion der Aufrufe der sart Implementierung der GLIBC. In der unoptimierten Variante wird die Fläche area als Länge des Normalenvektors berechnet:

Listing 4: Assembler Berechnung area

```
T area = normal.length(); // used for u-v-parameter calculation
6392: 48 8d 85 7c ff ff ff lea -0x84(%rbp),%rax
6399: 48 89 c7 mov %rax,%rdi
639c: e8 ed fa ff ff callq 5e8e <\_ZNK6VectorIfLm3EE6lengthEv>
63a1: c5 f9 7e c0 vmovd %xmm0,%eax
63a5: 89 45 f8 mov %eax,-0x8(%rbp)
```

Die Berechnung der Länge erfolgt in der Funktion Vector::length:

Listing 5: Assembler Vector::length

```
T length(void) const {
    5e8e: 55 push %rbp
    5e8f: 48 89 e5 mov %rsp,%rbp
    5e92: 48 83 ec 10 sub $0x10,%rsp
    5e96: 48 89 7d f8 mov %rdi,-0x8(%rbp)
    return sqrt( square_of_length() );
```

Dazu wird zunächst square_of_length() aufgerufen (5ea1) und mit dem Ergebnis die GLIBC Implementierung der sqrt Funktion aufgerufen (5eb4). Auch für die Berechnung von u und v wird Vector::length() aufgerufen:

Listing 6: Assembler Berechnung u und v, unoptimiert

```
1
   u = vector.length() / area;
 2
   6726: 48 8d 85 64 ff ff ff lea -0x9c(%rbp), %rax
   672d: 48 89 c7 mov %rax, %rdi
 3
   6730: e8 59 f7 ff ff callq 5e8e <\_ZNK6VectorIfLm3EE6lengthEv>
 4
   6735: c5 fa 5e 45 f8 vdivss -0x8(%rbp), %xmm0, %xmm0
 5
   673a: 48 8b 85 28 ff ff ff mov -0xd8(%rbp),%rax
   6741: c5 fa 11 00 vmovss %xmm0,(%rax)
 7
8
9
   v = vector.length() / area;
   685b: 48 8d 85 64 ff ff ff lea -0x9c(%rbp), %rax
   6862: 48 89 c7 mov %rax, %rdi
11
   6865: e8 24 f6 ff ff callq 5e8e <\ ZNK6VectorIfLm3EE6lengthEv>
   686a: c5 fa 5e 45 f8 vdivss -0x8(%rbp), %xmm0, %xmm0
14
  686f: 48 8b 85 20 ff ff ff mov -0xe0(%rbp), %rax
15
  6876: c5 fa 11 00 vmovss %xmm0,(%rax)
```

Insgesamt macht das 3 Aufrufe von sqrt (67830 und 6865 über Vector::length). Die optimierte Version verwendet die Vector::length Funktion nicht. Da für die Berechnung von u und v standardmäßig jeweils zwei Quadratwurzeln dividiert werden, kann die Wurzelberechnung auch auf das Ergebnis der Division erfolgen und damit verzögert werden. In der optimierten Version werden deshalb nur 2 Aufrufe von sqrt benötigt (6876 und 68ac).

Listing 7: Assembler Berechnung u und v, optimiert

```
6863: c5 fa 5e 45 f4 vdivss -0xc(%rbp), %xmm0, %xmm0
   6868: c5 d2 5a e8 vcvtss2sd %xmm0,%xmm5,%xmm5
  686c: c4 e1 f9 7e e8 vmovq %xmm5, %rax
8 | 6871: c4 e1 f9 6e c0 vmovq %rax, %xmm0
9
  6876: e8 85 b8 ff ff callq 2100 <sqrt@plt>
  687b: c5 fb 5a c0 vcvtsd2ss %xmm0,%xmm0,%xmm0
  687f: 48 8b 85 10 ff ff ff mov -0xf0(%rbp),%rax
  6886: c5 fa 11 00 vmovss %xmm0,(%rax)
   u = sqrt(vector.square_of_length() / squareArea);
   688a: 48 8d 85 64 ff ff ff lea -0x9c(%rbp), %rax
  6891: 48 89 c7 mov %rax, %rdi
16 | 6894: e8 dd 07 00 00 callq 7076 <\
       → _ZNK6VectorIfLm3EE16square_of_lengthEv>
  6899: c5 fa 5e 45 f4 vdivss -0xc(%rbp), %xmm0, %xmm0
17
  689e: c5 ca 5a f0 vcvtss2sd %xmm0,%xmm6,%xmm6
  68a2: c4 e1 f9 7e f0 vmovq %xmm6, %rax
   68a7: c4 e1 f9 6e c0 vmovq %rax, %xmm0
   68ac: e8 4f b8 ff ff callq 2100 <sqrt@plt>
   68b1: c5 fb 5a c0 vcvtsd2ss %xmm0,%xmm0,%xmm0
   68b5: 48 8b 85 18 ff ff ff mov -0xe8(%rbp), %rax
   68bc: c5 fa 11 00 vmovss %xmm0,(%rax)
```

Messungen

Kompiliert wurde jeweils unter Debian 10 mit GCC 8.3.0. Die Messungen wurden auf einem PC mit folgenden Merkmalen erstellt:

* CPU: AMD Ryzen 7 5800X @ 4.60 GHz

* RAM: 32GB DDR4-3200

Messung

Durchlauf	Zeit Optimiert	Zeit unoptimiert
1	4.62049 s	4.02156 s
2	4.60774 s	4.07757 s
3	4.56693 s	4.06602 s
4	$4.56833 \ s$	4.04903 s
5	4.58256 s	$4.07341 \mathrm{\ s}$
6	4.58978 s	4.0889 s
7	4.56290 s	$4.09844 \mathrm{\ s}$
8	4.57446 s	4.09043 s
9	4.55789 s	$4.08588 \mathrm{\ s}$
10	4.59217 s	4.0745 s

Durchlauf	Zeit Optimiert	Zeit unoptimiert
Durchschnitt	4.582325 s	$4.072574 \mathrm{\ s}$

Ergibt eine Performance-Steigerung von etwa +12,5 %. Zurückzuführen ist diese Steigerung auf die Reduktion der Quadratwurzelberechnung. Durch die Ausführung der Berechnungen am Ende der Funktion werden Quadratwurzeln nur noch berechnet wenn dies notwendig ist. Zusätzlich wurde die maximale Anzahl der Quadratwurzelberechnungen reduziert und durch die Prüfung, ob bereits nähere Schnittpunkte gefunden wurden, kann die Berechnung häufiger frühzeitig abgebrochen werden.

2. Quadratwurzelberechnung optimieren

Optimierung der Quadratwurzelberechnung durch Verwendung des Newton-Verfahrens. Wo möglich wird der Assembler-Code ohne Compileroptimierung verwendet, um die Lesbarkeit zu erhöhen. Sourcecode sqrt1:

Listing 8: sqrt1

```
1
   template <size t LOOPS = 2>
 2
   float sqrt1(float *a)
 3
   {
 4
     float root;
 5
6
     int *ai = reinterpret_cast<int *>(a);
 7
     int *initial = reinterpret_cast<int *>(&root);
     *initial = (1 << 29) + (*ai >> 1) - (1 << 22) - 0x4C000;
8
9
     root = *reinterpret_cast<float *>(initial);
10
     // newton method
     for (size_t i = 0; i < LOOPS; i++)</pre>
11
12
13
       root = 0.5 * (root + *a / root);
14
15
16
     return root;
17
```

Der Assembler-Code für den Aufruf von sqrt1 mit der SIMD-Optimierung durch den Compiler:

Listing 9: sqrt1 Assembler

```
1
          start = steady_clock::now()
 2
       18bf: e8 4c f8 ff ff callq 1110 <
           → _ZNSt6chrono3_V212steady_clock3nowEv@plt>
       18c4: b9 e8 03 00 00 mov $0x3e8, %ecx
 3
 4
       18c9: c5 f8 28 25 3f 08 00 vmovaps 0x83f(%rip),%xmm4 # 2110 <

→ _IO_stdin_used+0x110>

 5
       18d0: 00
 6
       18d1: c5 f8 28 1d 47 08 00 vmovaps 0x847(%rip),%xmm3 # 2120 <

→ _IO_stdin_used+0x120>

 7
       18d8: 00
       18d9: 49 89 c7 mov %rax, %r15
 8
9
       18dc: 48 89 44 24 60 mov %rax,0x60(%rsp)
       18e1: 66 66 2e 0f 1f 84 00 data16 nopw %cs:0x0(%rax, %rax,1)
10
11
       18e8: 00 00 00 00
12
       18ec: Of 1f 40 00 nopl 0x0(%rax)
13
       18f0: 4c 89 e2 mov %r12, %rdx
14
       18f3: 4c 89 e8 mov %r13, %rax
```

```
15
      *initial = (1 << 29) + (*ai >> 1) - (1 << 22) - 0x4C000;
16
        18f6: c5 f8 28 32 vmovaps (%rdx),%xmm6
17
        18fa: c5 f8 28 42 20 vmovaps 0x20(%rdx),%xmm0
18
       18ff: 48 83 c0 40 add $0x40, %rax
19
        1903: 48 83 c2 40 add $0x40, %rdx
20
       1907: c5 c8 c6 52 d0 88 vshufps $0x88,-0x30(%rdx),%xmm6,%xmm2
21
        190d: c5 f8 c6 4a f0 88 vshufps $0x88,-0x10(%rdx),%xmm0,%xmm1
22
       1913: c5 c8 c6 72 d0 dd vshufps $0xdd, -0x30(%rdx), %xmm6, %xmm6
23
       1919: c5 f8 c6 42 f0 dd vshufps $0xdd, -0x10(%rdx), %xmm0, %xmm0
24
       191f: c5 e8 c6 e9 88 vshufps $0x88, %xmm1, %xmm2, %xmm5
25
       1924: c5 e8 c6 c9 dd vshufps $0xdd, %xmm1, %xmm2, %xmm1
26
       1929: c5 c8 c6 d0 88 vshufps $0x88, %xmm0, %xmm6, %xmm2
27
        192e: c5 c8 c6 c0 dd vshufps $0xdd, %xmm0, %xmm6, %xmm0
28
       1933: c5 c9 72 e5 01 vpsrad $0x1, %xmm5, %xmm6
29
       1938: c5 c9 fe fc vpaddd %xmm4, %xmm6, %xmm7
30
       root = 0.5 * (root + *a / root)
31
       193c: c5 d0 5e f7 vdivps %xmm7, %xmm5, %xmm6
32
       1940: c5 c8 58 f7 vaddps %xmm7, %xmm6, %xmm6
33
       1944: c5 c8 59 f3 vmulps %xmm3,%xmm6,%xmm6
34
        1948: c5 d0 5e ee vdivps %xmm6, %xmm5, %xmm5
35
       194c: c5 d0 58 ee vaddps %xmm6, %xmm5, %xmm5
36
      *initial = (1 << 29) + (*ai >> 1) - (1 << 22) - 0x4C000;
37
        1950: c5 c9 72 e2 01 vpsrad $0x1, %xmm2, %xmm6
38
       1955: c5 c9 fe fc vpaddd %xmm4, %xmm6, %xmm7
39
       root = 0.5 * (root + *a / root);
40
       1959: c5 e8 5e f7 vdivps %xmm7, %xmm2, %xmm6
41
       195d: c5 d0 59 eb vmulps %xmm3, %xmm5, %xmm5
        1961: c5 c8 58 f7 vaddps %xmm7, %xmm6, %xmm6
42
43
       1965: c5 c8 59 f3 vmulps %xmm3, %xmm6, %xmm6
44
       1969: c5 e8 5e d6 vdivps %xmm6, %xmm2, %xmm2
45
       196d: c5 e8 58 d6 vaddps %xmm6, %xmm2, %xmm2
46
     *initial = (1 << 29) + (*ai >> 1) - (1 << 22) - 0x4C000;
47
        1971: c5 c9 72 e1 01 vpsrad $0x1, %xmm1, %xmm6
48
       1976: c5 c9 fe fc vpaddd %xmm4, %xmm6, %xmm7
49
       root = 0.5 * (root + *a / root)
50
       197a: c5 f0 5e f7 vdivps %xmm7, %xmm1, %xmm6
51
       197e: c5 e8 59 d3 vmulps %xmm3, %xmm2, %xmm2
       1982: c5 c8 58 f7 vaddps %xmm7, %xmm6, %xmm6
52
53
       1986: c5 c8 59 f3 vmulps %xmm3, %xmm6, %xmm6
54
       198a: c5 f0 5e ce vdivps %xmm6, %xmm1, %xmm1
       198e: c5 f0 58 ce vaddps %xmm6, %xmm1, %xmm1
55
56
     *initial = (1 << 29) + (*ai >> 1) - (1 << 22) - 0x4C000;
57
       1992: c5 c9 72 e0 01 vpsrad $0x1, %xmm0, %xmm6
58
       1997: c5 c9 fe fc vpaddd %xmm4, %xmm6, %xmm7
59
       root = 0.5 * (root + *a / root);
       199b: c5 f8 5e f7 vdivps %xmm7, %xmm0, %xmm6
60
```

```
199f: c5 f0 59 cb vmulps %xmm3, %xmm1, %xmm1
61
62
        19a3: c5 c8 58 f7 vaddps %xmm7, %xmm6, %xmm6
63
        19a7: c5 c8 59 f3 vmulps %xmm3, %xmm6, %xmm6
64
        19ab: c5 f8 5e c6 vdivps %xmm6, %xmm0, %xmm0
65
        19af: c5 f8 58 c6 vaddps %xmm6, %xmm0, %xmm0
66
           roots[i + k] = sqrt1<LOOPS>(floats + i + k);
67
       19b3: c5 d0 14 f1 vunpcklps %xmm1, %xmm5, %xmm6
68
        19b7: c5 d0 15 c9 vunpckhps %xmm1, %xmm5, %xmm1
69
        19bb: c5 f8 59 c3 vmulps %xmm3,%xmm0,%xmm0
70
       19bf: c5 e8 14 e8 vunpcklps %xmm0, %xmm2, %xmm5
71
       19c3: c5 e8 15 c0 vunpckhps %xmm0, %xmm2, %xmm0
72
       19c7: c5 c8 14 d5 vunpcklps %xmm5, %xmm6, %xmm2
        19cb: c5 c8 15 f5 vunpckhps %xmm5, %xmm6, %xmm6
73
       19cf: c5 f8 29 50 c0 vmovaps %xmm2,-0x40(%rax)
74
75
       19d4: c5 f0 14 d0 vunpcklps %xmm0, %xmm1, %xmm2
76
       19d8: c5 f0 15 c8 vunpckhps %xmm0, %xmm1, %xmm1
77
       19dc: c5 f8 29 70 d0 vmovaps %xmm6,-0x30(%rax)
78
        19e1: c5 f8 29 50 e0 vmovaps %xmm2,-0x20(%rax)
79
        19e6: c5 f8 29 48 f0 vmovaps %xmm1,-0x10(%rax)
80
        19eb: 49 39 c6 cmp %rax, %r14
```

Die zweite Variante berechnet vier Wurzeln gleichzeitig. Der Compiler erzeugt dazu auch hier automatisch die Packed-SIMD Instruktionen.

Listing 10: sqrt2

```
1
   template <size_t LOOPS = 2>
 2
   void sqrt2(float *__restrict__ a, float *__restrict__ root)
 3
 4
     int *ai = reinterpret_cast<int *>(a);
 5
     int *initial = reinterpret cast<int *>(root);
 6
     initial[0] = (1 \iff 29) + (ai[0] \implies 1) - (1 \iff 22) - 0x4C000;
 7
     initial[1] = (1 << 29) + (ai[1] >> 1) - (1 << 22) - 0x4C000;
 8
     initial[2] = (1 << 29) + (ai[2] >> 1) - (1 << 22) - 0x4C000;
 9
     initial[3] = (1 << 29) + (ai[3] >> 1) - (1 << 22) - 0x4C000;
10
     root = reinterpret_cast<float *>(initial);
11
     // newton method
12
     for (size_t i = 0; i < LOOPS; i++)</pre>
13
14
       root[0] = 0.5 * (root[0] + a[0] / root[0]);
15
       root[1] = 0.5 * (root[1] + a[1] / root[1]);
16
       root[2] = 0.5 * (root[2] + a[2] / root[2]);
17
       root[3] = 0.5 * (root[3] + a[3] / root[3]);
     }
18
19
```

Der Assembler-Code für sqrt2 wurde mit Optimierung (-O3) erzeugt, damit die Packed-SIMD Instruktionen verwendet werden. Durch Optimierungen wie Inlining wird der Assembler-Code allerdings schwer lesbar und Anfang und Ende einer Funktion sind nur schwer identifizierbar. Um dennoch lesbaren Assembler-Code zu erhalten wurde die Main-Funktion angepasst, sodass nur noch die Funktion sqrt2 mit zufälligen Zahlen mehrfach aufgerufen wird.

Listing 11: Assembler für sqrt2

```
template <size t LOOPS = 2>
 1
 2
    void sqrt2(float *__restrict__ a, float *__restrict__ root)
 3
      int *ai = reinterpret_cast<int *>(a);
 4
 5
      int *initial = reinterpret_cast<int *>(root);
      initial[0] = (1 << 29) + (ai[0] >> 1) - (1 << 22) - 0x4C000;
 6
 7
       1190: c4 c1 78 28 44 24 20 vmovaps 0x20(%r12),%xmm0
      initial[3] = (1 << 29) + (ai[3] >> 1) - (1 << 22) - 0x4C000;
9
      root = reinterpret_cast<float *>(initial);
10
      // newton method
11
      for (size_t i = 0; i < LOOPS; i++)</pre>
12
13
       root[0] = 0.5 * (root[0] + a[0] / root[0]);
14
       1197: c5 f8 28 60 20 vmovaps 0x20(%rax), %xmm4
       119c: 48 83 c0 40 add $0x40, %rax
15
16
        11a0: 49 83 c4 40 add $0x40, %r12
      initial[0] = (1 << 29) + (ai[0] >> 1) - (1 << 22) - 0x4C000;
17
18
        11a4: c4 c1 78 28 4c 24 c0 vmovaps -0x40(%r12), %xmm1
        11ab: c4 41 78 c6 54 24 f0 vshufps $0x88,-0x10(%r12),%xmm0,%
19
            \hookrightarrow xmm10
20
        11b2: 88
21
       11b3: c4 41 78 c6 44 24 f0 vshufps $0xdd, -0x10(%r12), %xmm0, %
            \hookrightarrow xmm8
22
       11ba: dd
23
       root[0] = 0.5 * (root[0] + a[0] / root[0]);
24
        11bb: c5 f8 28 40 c0 vmovaps -0x40(%rax),%xmm0
25
        11c0: c5 d8 c6 50 f0 88 vshufps $0x88, -0x10(%rax), %xmm4, %xmm2
26
      initial[0] = (1 << 29) + (ai[0] >> 1) - (1 << 22) - 0x4C000;
27
        11c6: c4 c1 70 c6 5c 24 d0 vshufps $0x88,-0x30(%r12),%xmm1,%
            \hookrightarrow xmm3
28
       11cd: 88
29
       root[0] = 0.5 * (root[0] + a[0] / root[0]);
30
        11ce: c5 d8 c6 60 f0 dd vshufps $0xdd, -0x10(%rax), %xmm4, %xmm4
      initial[0] = (1 << 29) + (ai[0] >> 1) - (1 << 22) - 0x4C000;
31
32
        11d4: c4 c1 70 c6 4c 24 d0 vshufps $0xdd, -0x30(%r12), %xmm1,%
            \hookrightarrow xmm1
33
       11db: dd
34
       root[0] = 0.5 * (root[0] + a[0] / root[0]);
```

```
35
        11dc: c5 78 c6 48 d0 88 vshufps $0x88, -0x30(%rax), %xmm0, %xmm9
36
        11e2: c5 f8 c6 40 d0 dd vshufps $0xdd, -0x30(%rax), %xmm0, %xmm0
37
      initial[0] = (1 << 29) + (ai[0] >> 1) - (1 << 22) - 0x4C000;
38
        11e8: c4 c1 60 c6 ea 88 vshufps $0x88, %xmm10, %xmm3, %xmm5
39
       root[0] = 0.5 * (root[0] + a[0] / root[0]);
40
       11ee: c5 f8 c6 fc 88 vshufps $0x88, %xmm4, %xmm0, %xmm7
       11f3: c5 30 c6 da 88 vshufps $0x88, %xmm2, %xmm9, %xmm11
41
        11f8: c5 f8 c6 e4 dd vshufps $0xdd, %xmm4, %xmm0, %xmm4
42
43
      initial[0] = (1 << 29) + (ai[0] >> 1) - (1 << 22) - 0x4C000;
44
        11fd: c4 c1 70 c6 c0 88 vshufps $0x88, %xmm8, %xmm1, %xmm0
       root[0] = 0.5 * (root[0] + a[0] / root[0]);
45
46
       1203: c4 c1 50 5e eb vdivps %xmm11,%xmm5,%xmm5
47
       1208: c5 30 c6 ca dd vshufps $0xdd, %xmm2, %xmm9, %xmm9
48
       root[1] = 0.5 * (root[1] + a[1] / root[1]);
49
       120d: c5 f8 5e c7 vdivps %xmm7, %xmm0, %xmm0
50
       root[0] = 0.5 * (root[0] + a[0] / root[0])
51
       1211: c4 c1 50 58 d3 vaddps %xmm11,%xmm5,%xmm2
52
        1216: c5 e8 59 ee vmulps %xmm6, %xmm2, %xmm5
53
     initial[0] = (1 << 29) + (ai[0] >> 1) - (1 << 22) - 0x4C000;
54
        121a: c4 c1 60 c6 d2 dd vshufps $0xdd, %xmm10, %xmm3, %xmm2
55
       root[1] = 0.5 * (root[1] + a[1] / root[1]);
56
       1220: c5 f8 58 c7 vaddps %xmm7, %xmm0, %xmm0
57
       root[2] = 0.5 * (root[2] + a[2] / root[2]);
58
       1224: c4 c1 68 5e d1 vdivps %xmm9, %xmm2, %xmm2
59
       root[1] = 0.5 * (root[1] + a[1] / root[1]);
       1229: c5 f8 59 fe vmulps %xmm6,%xmm0,%xmm7
60
61
     initial[0] = (1 << 29) + (ai[0] >> 1) - (1 << 22) - 0x4C000;
        122d: c4 c1 70 c6 c0 dd vshufps $0xdd, %xmm8, %xmm1, %xmm0
62
63
       root[3] = 0.5 * (root[3] + a[3] / root[3]);
64
       1233: c5 f8 5e c4 vdivps %xmm4, %xmm0, %xmm0
65
       root[2] = 0.5 * (root[2] + a[2] / root[2])
66
       1237: c4 c1 68 58 d1 vaddps %xmm9, %xmm2, %xmm2
67
       123c: c5 e8 59 d6 vmulps %xmm6, %xmm2, %xmm2
68
       root[3] = 0.5 * (root[3] + a[3] / root[3]);
69
        1240: c5 d0 14 ca vunpcklps %xmm2, %xmm5, %xmm1
70
       1244: c5 d0 15 d2 vunpckhps %xmm2, %xmm5, %xmm2
71
       1248: c5 f8 58 c4 vaddps %xmm4, %xmm0, %xmm0
72
       124c: c5 f8 59 c6 vmulps %xmm6, %xmm0, %xmm0
73
        1250: c5 c0 14 d8 vunpcklps %xmm0, %xmm7, %xmm3
74
       1254: c5 c0 15 c0 vunpckhps %xmm0, %xmm7, %xmm0
       1258: c5 f0 14 e3 vunpcklps %xmm3, %xmm1, %xmm4
75
76
       125c: c5 f0 15 cb vunpckhps %xmm3, %xmm1, %xmm1
77
       1260: c5 f8 29 48 d0 vmovaps %xmm1,-0x30(%rax)
78
       1265: c5 e8 14 c8 vunpcklps %xmm0, %xmm2, %xmm1
79
       1269: c5 e8 15 d0 vunpckhps %xmm0, %xmm2, %xmm2
80
       126d: c5 f8 29 60 c0 vmovaps %xmm4,-0x40(%rax)
```

Im Assembler-Code fällt auf, dass die Packed-SIMD Instruktionen vdivps, vaddps und vmulps für die Berechnung der Wurzeln verwendet werden. Außerdem ist zu sehen, dass der Compiler ein Loop-Unrolling durchgeführt hat.#

Für die dritte Variante werden Packed-SIMD Instruktionen genutzt um 4 Werte gleichzeitig zu berechnen. Sourcecode v4sf_sqrt:

Listing 12: v4sf_sqrt

```
template <size_t LOOPS = 2>
 1
 2
   float v4sf_sqrt(float *a)
 3
     v4si *ai = reinterpret_cast<v4si *>(a);
 4
     v4si *initial = reinterpret_cast<v4si *>(root);
 5
 6
     *initial = (1 << 29) + (*ai >> 1) - (1 << 22) - 0x4C000;
 7
 8
     root = reinterpret_cast<v4sf *>(initial);
9
     // newton method
10
     for (size_t i = 0; i < LOOPS; i++)</pre>
11
12
        *root = 0.5 * (*root + *a / *root);
13
14
```

Durch die Verwendung der Compiler-Intrinsics, verwendet der Compiler die Packed-SIMD Instruktionen auch ohne Compiler-Optimierung. Deshalb kann hier der unoptimierte, besser lesbare Assembler verwendet werden.

Listing 13: v4sf_sqrt Assembler

```
1
    void v4sf_sqrt(v4sf *__restrict__ a, v4sf *__restrict__ root)
 2
       22fb: 55 push %rbp
 3
       22fc: 48 89 e5 mov %rsp,%rbp
 4
       22ff: 48 89 7d d8 mov %rdi,-0x28(%rbp)
       2303: 48 89 75 d0 mov %rsi,-0x30(%rbp)
 5
 6
     v4si *ai = reinterpret_cast<v4si *>(a);
 7
       2307: 48 8b 45 d8 mov -0x28(%rbp), %rax
       230b: 48 89 45 f0 mov %rax,-0x10(%rbp)
 8
9
     v4si *initial = reinterpret_cast<v4si *>(root);
10
       230f: 48 8b 45 d0 mov -0x30(%rbp),%rax
       2313: 48 89 45 e8 mov %rax,-0x18(%rbp)
11
     *initial = (1 << 29) + (*ai >> 1) - (1 << 22) - 0x4C000;
12
13
       2317: 48 8b 45 f0 mov -0x10(%rbp),%rax
```

```
14
       231b: c5 f8 28 00 vmovaps (%rax), %xmm0
15
       231f: c5 f1 72 e0 01 vpsrad $0x1, %xmm0, %xmm1
16
       2324: c5 f8 28 05 24 0e 00 vmovaps 0xe24(%rip),%xmm0 # 3150 <

→ _ZStL19piecewise_construct+0x140>
17
       232b: 00
18
       232c: c5 f1 fe c0 vpaddd %xmm0, %xmm1, %xmm0
       2330: 48 8b 45 e8 mov -0x18(%rbp),%rax
19
20
       2334: c5 f8 29 00 vmovaps %xmm0,(%rax)
21
     root = reinterpret cast<v4sf *>(initial);
22
       2338: 48 8b 45 e8 mov -0x18(%rbp), %rax
23
       233c: 48 89 45 d0 mov %rax,-0x30(%rbp)
24
     for (size_t i = 0; i < LOOPS; i++)
25
       2340: 48 c7 45 f8 00 00 00 movq $0x0,-0x8(%rbp)
26
       2347: 00
27
       2348: 48 83 7d f8 01 cmpq $0x1,-0x8(%rbp)
28
       234d: 77 3a ja 2389 <_Z9v4sf_sqrtILm2EEvPDv4_fS1_+0x8e>
29
       *root = 0.5 * (*root + *a / *root);
30
       234f: 48 8b 45 d0 mov -0x30(%rbp), %rax
31
       2353: c5 f8 28 08 vmovaps (%rax), %xmm1
32
       2357: 48 8b 45 d8 mov -0x28(%rbp), %rax
33
       235b: c5 f8 28 00 vmovaps (%rax), %xmm0
34
       235f: 48 8b 45 d0 mov -0x30(%rbp), %rax
35
       2363: c5 f8 28 10 vmovaps (%rax), %xmm2
36
       2367: c5 f8 5e c2 vdivps %xmm2,%xmm0,%xmm0
       236b: c5 f0 58 c8 vaddps %xmm0,%xmm1,%xmm1
37
38
       236f: c5 f8 28 05 e9 0d 00 vmovaps 0xde9(%rip),%xmm0 # 3160 <
           → _ZStL19piecewise_construct+0x150>
39
       2376: 00
40
       2377: c5 f0 59 c0 vmulps %xmm0, %xmm1, %xmm0
41
       237b: 48 8b 45 d0 mov -0x30(%rbp),%rax
42
       237f: c5 f8 29 00 vmovaps %xmm0,(%rax)
43
     for (size_t i = 0; i < LOOPS; i++)
44
       2383: 48 ff 45 f8 incq -0x8(%rbp)
45
       2387: eb bf jmp 2348 <_Z9v4sf_sqrtILm2EEvPDv4_fS1_+0x4d>
46
47
       2389: 90 nop
48
       238a: 5d pop %rbp
49
       238b: c3 retq
```

Messungen

Kompiliert wurde jeweils unter Debian 10 mit GCC 7.4.0. Die GCC Version 8.3.0 lieferte durch zusätzliche Optimierungen für sqrt3 Zeiten von unter 1000 ns, was im Vergleich mit den anderen Zeiten unrealistisch erscheint, eventuell wurden Optimierungen durchgeführt, welche die Zeitmessung beeinflussen. Die

$2. \ Quadrat wurzelberechnung optimieren$

Messungen wurden auf einem PC mit folgenden Merkmalen erstellt:

* CPU: AMD Ryzen 7 5800X @ 4.60 GHz

* RAM: 32GB DDR4-3200

2 Iterationen

	math.sqrt	sqrt1		sqrt2	sqrt3
Durchlauf	[ns]	[ns]	sqrt1*4 [ns]	[ns]	[ns]
1	1244731	132099	159254	157880	132355
2	1232933	131793	158757	158193	131847
3	1244356	131728	158531	158055	131932
4	1238731	132128	158533	157230	131758
5	1241204	132227	158571	157943	134218
6	1240188	132393	158445	157378	131885
7	1253477	132444	158934	157814	137585
8	1240861	133277	161816	159400	132265
9	1243250	131988	158477	157781	132435
10	1244608	132120	159346	157520	132092
_					_
Durchschnit	t 1242433.9	132219.7	159066.4	157919.4	132837.2

3 Iterationen

	$_{\mathrm{math.sqrt}}$				
Durchlauf	[ns]	sqrt1 [ns]	sqrt1*4 [ns]	sqrt2 [ns]	sqrt3 [ns]
1	1274224	199425	231799	235836	200774
2	1241694	197401	230817	235878	198245
3	1244044	197625	231488	234478	198096
4	1241951	197603	230895	234020	197587
5	1243158	199289	231197	235173	198257
6	1242758	200338	238524	234554	201696
7	1251411	197677	231318	234644	198069
8	1240883	197868	231052	233187	198576
9	1246030	198530	231148	233217	198022
10	1242813	197660	231288	233682	197976
		_	_		
Durchschnitt	1246896.6	198341.6	231952.6	234466.9	198729.8

4 Iterationen

	math.sqrt				
Durchlauf	[ns]	sqrt1 [ns]	sqrt1*4 [ns]	sqrt2 [ns]	sqrt3 [ns]
1	1250898	270484	319153	319681	269713
2	1242425	267495	316088	317749	267528
3	1245181	268141	316043	317910	267465
4	1244542	268034	316127	317757	271406
5	1243158	199289	231197	235173	198257
6	1254091	268371	316607	333658	274396
7	1246632	267236	317179	318522	268319
8	1244199	267383	315701	318046	267868
9	1242659	267807	315654	317933	269594
10	1243171	267500	315900	318000	267500
_	_	_	_	_	
Durchschnitt	1245695.6	261174	307964.9	311442.9	262204.6

Wie erwartet, ist jede der optimierten Versionen schneller als die Standard-Implementierung der GLIBC. Ebenfalls wie erwartet, steigt die Ausfürhungszeit mit der Anzahl der Anzahl Iterationen.

Die Variante sqrt1 mit nur zwei Iterationen ist am schnellsten, gefolgt von der Variante sgrt3 welche SIMD-Befehle nutzt um die Berechnung mehrerer Quadratwurzeln zu beschleunigen. Die Variante sqrt2 ist etwas langsamer als sqrt3, was vermutlich auf schlechtere Optimierung durch den Compiler bei Verzicht auf die Nutzung der SIMD-Intrinsics zurückzuführen ist.# Die Automatische Vektorisierung durch den Compiler scheint schlechter zu funktionieren als die manuelle Optimierung durch die Verwendung von SIMD-Intrinsics. Allerdings sind die Unterschiede vergleichsweise klein. Dass sort1 mit der zusätzlichen inneren Schleife langsamer ist als sqrt1, lässt sich darauf zurückführen, dass der Compiler die verschachtelten Schleifen weniger gut optimieren kann als die einzelne Schleife. Erwartet wurde, dass die Vektorisierte Variante sgrt3 schneller ist als die Variante sgrt1, da die SIMD-Instruktionen die Berechnung von mehreren Quadratwurzeln gleichzeitig ermöglichen. Jedoch ist die Quadratwurzelberechnung vergleichsweise einfach, sodass ein großer Teil der Berechnungszeit auf Speicherbefehle (Load/Store) entfällt und die SIMD-Instruktionen ihr volles Potenzial nicht ausschöpfen können.

3. Optimierung mittels k-d-Baum

Bei dieser Optimierung werden die Dreiecke in einem k-d-Baum abhängig von ihrer Position gespeichert. So können die Shnittpunkttests auf Dreiecke reduziert werden, welche in einem Bereich liegen, durch welchen der Sehstrahl verläuft. Dreiecke, welche in anderen räumlichen Bereichen liegen und vom Sehstrahl nicht getroffen werden können, müssen nicht weiter überprüft werden. Damit lässt sich die Gesamtzahl der Shnittpunkttests reduzieren.

Listing 14: BoundingBox::split

```
1
    void BoundingBox::split(BoundingBox &left, BoundingBox &right)
2
3
      float lengthX = std::abs(max[0] - min[0]);
 4
      float lengthY = std::abs(max[1] - min[1]);
      float lengthZ = std::abs(max[2] - min[2]);
 5
 6
 7
      // min/max points are always the same, only set the missing
          \hookrightarrow point during split
8
      left.min = min;
9
      right.max = max;
10
11
      if (lengthX >= lengthY && lengthX >= lengthZ)
12
13
        float newWidth = lengthX / 2;
14
        left.max = Vector<float, 3>{min[0] + newWidth, max[1], max
            \hookrightarrow [2]};
        right.min = Vector<float, 3>{min[0] + newWidth, min[1], min
15
            \hookrightarrow [2]};
16
       return;
      }
17
18
19
      if (lengthY >= lengthX && lengthY >= lengthZ)
20
21
        float newWidth = lengthY / 2;
22
        left.max = Vector<float, 3>{max[0], min[1] + newWidth, max
23
       right.min = Vector<float, 3>{min[0], min[1] + newWidth, min
            \hookrightarrow [2]};
24
        return;
25
      }
26
27
      float newWidth = lengthZ / 2;
28
      left.max = Vector<float, 3>{max[0], max[1], min[2] + newWidth};
      right.min = Vector<float, 3>{min[0], min[1], min[2] + newWidth
29
          \hookrightarrow };
30
```

Listing 15: BoundingBox::contains implementierungen

Listing 16: public KDTree::buildTree

```
KDTree *KDTree::buildTree(std::vector<Triangle<FLOAT> *> &
        → triangles)
 2
   {
 3
     KDTree *root = new KDTree();
 4
      // find min and max coordinates
      auto min = Vector<float, 3>{triangles[0]->p1[0], triangles[0]->
 5
          \hookrightarrow p1[0], triangles[0]->p1[0]};
      auto max = Vector<float, 3>{triangles[0]->p1[0], triangles[0]->
 6
          \hookrightarrow p1[0], triangles[0]->p1[0]};
 7
 8
      for (auto iterator = std::next(triangles.begin()); iterator !=
          → triangles.end(); ++iterator)
 9
10
        Triangle<float> *triangle = *iterator;
11
       min[0] = std::min({min[0], triangle->p1[0], triangle->p2[0],
            \hookrightarrow triangle->p3[0]});
12
       min[1] = std::min({min[1], triangle->p1[1], triangle->p2[1],

    triangle->p3[1]});
       min[2] = std::min({min[2], triangle->p1[2], triangle->p2[2],
13

    triangle->p3[2]});
14
       max[0] = std::max({max[0], triangle->p1[0], triangle->p2[0],}
15

    triangle->p3[0]});
16
       max[1] = std::max({max[1], triangle->p1[1], triangle->p2[1],
            \hookrightarrow triangle->p3[1]});
       max[2] = std::max({max[2], triangle->p1[2], triangle->p2[2],
17
            \hookrightarrow triangle->p3[2]});
18
      }
19
20
      // create bounding box
21
      root->box = BoundingBox(min, max);
22
      // use private constructor to build tree
23
      root->buildTree(root, triangles);
24
      return root;
25
```

Listing 17: private KDTree::buildTree

```
KDTree *KDTree::buildTree(KDTree *tree, std::vector<Triangle<</pre>
        → FLOAT> *> &triangles)
 2
    {
 3
 4
     // stop recursion
     if (triangles.size() <= MAX_TRIANGLES_PER_LEAF)</pre>
 5
 6
 7
      // copy triangles to this node
 8
       tree->triangles.insert(std::end(tree->triangles), std::begin(

    triangles), std::end(triangles));
 9
       return tree;
      }
10
11
12
      left = new KDTree();
13
     right = new KDTree();
      // split bounding box
14
      box.split(left->box, right->box);
15
16
17
      auto leftTriangles = std::vector<Triangle<float> *>();
18
      auto rightTriangles = std::vector<Triangle<float> *>();
19
20
      // assign triangles to left/right children
21
      for (auto const &triangle : triangles)
22
23
       bool leftContains = tree->left->box.contains(triangle);
24
       bool rightContains = tree->right->box.contains(triangle);
25
26
       if (leftContains && rightContains)
27
28
         tree->triangles.push_back(triangle);
29
       }else if (leftContains)
30
31
         leftTriangles.push back(triangle);
32
       } else
33
       {
34
         rightTriangles.push_back(triangle);
35
36
      }
37
38
      left = left->buildTree(left, leftTriangles);
39
      right = right->buildTree(right, rightTriangles);
40
      return tree;
41
```

Listing 18: public KDTree::hasNearestTriangle

```
bool KDTree::hasNearestTriangle(Vector<FLOAT, 3> eye, Vector<</pre>

→ FLOAT, 3> direction, Triangle
FLOAT> *&nearest_triangle,
        → FLOAT &t, FLOAT &u, FLOAT &v, FLOAT minimum_t)
 2
 3
      // check if ray intersects bounding box
 4
     if (!box.intersects(eye, direction))
 5
 6
       return false;
 7
 8
 9
      // check if ray intersects triangles in children
10
      if (this->left != nullptr)
11
12
       if (this->left->hasNearestTriangle(eye, direction,
           → nearest_triangle, t, u, v, minimum_t))
13
         minimum_t = t;
14
      }
15
      if (this->right != nullptr)
16
17
       if (this->right->hasNearestTriangle(eye, direction,
            → nearest_triangle, t, u, v, minimum_t))
18
         minimum_t = t;
19
      }
20
21
      // check if ray intersects triangles in this node
22
      for (auto triangle : this->triangles)
23
24
       stats.no_ray_triangle_intersection_tests++;
25
       // every call to triangle-> intersects will change the value
           \hookrightarrow of t, u, v but not minimum_t
26
       if (triangle->intersects(eye, direction, t, u, v, minimum_t))
27
         stats.no_ray_triangle_intersections_found++;
28
29
         nearest_triangle = triangle;
30
         minimum_t = t;
31
32
      }
33
34
      // set t to the found minimum (t could have changed since the
         \hookrightarrow minimum was found!)
35
      t = minimum_t;
36
      return nearest_triangle != nullptr;
37
```

Messungen

Kompiliert wurde jeweils unter Debian 10 mit GCC 8.3.0. Die Messungen wurden auf einem PC mit folgenden Merkmalen erstellt:

* CPU: AMD Ryzen 7 5800X @ 4.60 GHz

* RAM: 32GB DDR4-3200

Für die Zeiten für die Variante ohne k-d-Baum wurden die Messungen, die bei der ersten Optimierungsaufgabe erstellt wurden genutzt.

Durchlauf	Zeit ohne k-d-Baum	Zeit mit k-d-Baum
1	4.02156 s	1.00851 s
2	4.07757 s	1.10228 s
3	4.06602 s	1.03410 s
4	4.04903 s	1.00635 s
5	4.07341 s	$1.01284 \mathrm{\ s}$
6	$4.0889 \ s$	1.00778 s
7	4.09844 s	0.99733 s
8	4.09043 s	1.00634 s
9	$4.08588 \mathrm{\ s}$	1.00491 s
10	4.0745 s	1.00765 s
Durchschnitt	4.072574 s	1.018809 s

Im Schnitt ergibt sich durch den k-d-Baum eine Verbesserung von knapp 400~%. Die Variante mit k-d-Baum ist also knapp 4 mal schneller als die Variante ohne k-d-Baum.

Die Folgende Tabelle zeigt die Anzahl der durchgeführten Schnittpunkttests und die Anzahl der gefundenen Schnittpunkte. Zusätzlich zu den Varianten ohne und mit k-d-Baum werden auch die Daten des Raytracers ohne Optimierung des Schnittpunkttests angegeben.

	ohne	Ohne	Mit
	Optimierung	k-d-Baum	k-d-Baum
Anzahl Schnittpunkttests Anzahl gefundener Schnittpunkte	519.950.720 38.215	519.950.720 35.294	139.090.305 36.802

Die Schnittpunkttests wurden durch die Optimierung mit dem k-d-Baum um etwa Faktor 3,7 reduziert. Das entspricht im Wesentlichen der Verbesserung der Laufzeit. Allerdings ist die Anzahl der gefundenen Schnittpunkte mit dem k-d-Baum etwas höher als ohne k-d-Baum. Dies lässt sich auf die geänderte Reihenfolge der Schnittpunkttests zurückführen. Bei der komplett unoptimierten Variante werden alle Schnittpunkte gefunden, da bei bereits gefundenen

näheren Schnittpunkten nicht früher abgebrochen wird. Bei beiden optimierten Varianten kann früher abgebrochen werden. Allerdings hängt die Anzahl der Schnittpunkttests welche früher abgebrochen werden können von der Reihenfolge der Schnittpunkttests ab. Wird der nächste Schnittpunkt zum Beispiel beim ersten Test gefunden kann der Test für alle folgenden Dreiecke früher abgebrochen werden. Durch die räumliche Anordnung der Dreiecke in einem k-d-Baum ergibt sich eine andere Reihenfolge der Schnittpunkttests als ohne k-d-Baum. Deshalb liegt die Anzahl gefundener Schnittpunkte zwischen der Variante ohne k-d-Baum und der Variante ohne jegliche Optimierung, welche alle Schnittpunkte findet.